

e-Devlet UYGULAMASININ NLP İLE ANALİZİ VE SINIFLANDIRILMASI



Danışman :Onur Toka

Onur Güneş
Hacettepe Üniversitesi İstatistik Bölümü

NLP(Doğal Dil İşleme) Nedir ? :

Doğal Dil İşleme, bilgisayarlara insan dilini okuma, anlama ve yorumlama yeteneği veren bir yapay zeka uygulamasıdır. Spam tespiti , çeviri yapma, özet çıkarma ve duygu analizi alanlarında kullanılmaktadır.

e-Devlet Uygulaması Hakkında:




e-Devlet, vatandaşlara devlet tarafından verilen hizmetlerin elektronik ortamda sunulması demektir.Dijital kamu hizmetlerinin yaygın ve 7/24 erişilebilir hale getirmek ve devlet kamu kurumlarının verimliliğini arttırmak amacı ile kurulmuştur.



Veri Kümesi Hakkında :

Veri kümesi Google Play Store`da bulunan e-Devlet uygulamasının altına gelen 2023 yılının aralık ayının başlarından 2025 yılının aralık ayının başlarına kadar son 2 yılın yorumları oluşturmaktadır. Veri kümesinde 4954 yorum bulunmaktadır. Her yorum için tarih , uygulamaya verilen yıldız(1-5), yorumun başka kullanıcılar tarafından kaç kez beğenildiğini gösteren değişkenler bulunmaktadır.

Veri Kümesinin Betimsel Analizleri :



Metin Ön İşleme

Aşamaları:

Projemde metin ön işleme aşamasında büyük küçük harf farkından kaynaklanacak olan aynı kelime için farklı değer atanmaması için verimdeki her kelime öncelikle küçük harfe çevrildi, noktalama işaretleri cümlelerin anlamını değiştirmedikleri için kaldırıldı, gereksiz boşluklar kaldırıldı ve sayıların duygu analizi ve genel konu bulmada önemi olmayacağı için kaldırıldı. Sonrasında belli bir stop-word kümesi oluşturularak türkçede kullanılan ama anlam taşımayan kelimeler (ve ,ile...) kaldırıldı. Uygulamaya verilen 1 ve 2 yıldızlı yorumlar negatif (0) , 3 ve 4 yıldız verilen yorumlar pozitif (1) olarak etiketlenmiştir.

Karşılaşılan Sorunlar:

Metin ön işleme aşamasından sonra en çok geçen unique kelimelere bakıldığında frekansı en yüksek olan kelime “e” kelimesi çıktığı sonrasında frekansı yüksek diğer kelimeler incelendiğinde “yi”, “i” gibi kelimelerin çok geçtiği görülmüştür.

Çözüm :

Veri ile bigram ve trigram değerleri oluşturduğunda genel olarak “ e devlet “ , “ uygulama yi “ ve “ e devlet e “ , “e devlet i“ gibi kullanımlar yüzünden bu anlamsız kelimelerin frekansının yüksek olduğu tespit edilmiştir çözüm olarak bütün e harfleri silinip devlet kelimeleri edevlet olarak değiştirilmiş ve sadece ek olarak ayrı yazılan “yi“ ve “i“ kelimeleri tamamen silinmiştir.

LDA (Latent Dirichlet Allocation):

LDA analizi veride gizli kalmış konuları keşfetmek için kullanılmaktadır. Kümelemeye benzer şekilde çalışmaktadır.

Avantajları :

Etiketlenmemiş veri ile çalışabilir.

Büyük metinlerde çalışabilir.

Dezavantajları :

Konu sayısı kullanıcıya kalmıştır.

Parametre seçimi çok kritiktir.

Uygulanması :

İlk başta verime 5 konu bulacak şekilde LDA uygulanmıştır ama konulara bakıldığında bazı konular birbirine çok benzediği net bir ayrım olmadığı için konu sayısı 4` e düşürülünce güzel bir ayrım yakalandığından 4 konu olarak devam edilmiştir.

Sonuçlar:

Topic 1:

diyor, şifre, yeni, açılmıyor, hatası, sistem, nasıl, saçma, sorun, halde

Topic 2:

hata, veriyor, hata veriyor, nfc, giremiyorum, kimlik, açılmıyor, çalışmıyor, doğrulama, aşamalı

Topic 3:

giriş, atıyor, yapamıyorum, uygulamadan, giriş yapamıyordum, lütfen, işlem, kapanıyor, uygulamadan atıyor,

Topic 4:

şifre, teknik, sorun, diyor, diye, kadar, kabul, için,

İsimlendirme:

1:"Şifre ve Giriş Sorunları", 2:"Kimlik Doğrulama ve NFC Problemleri", 3: "Uygulama Çökmesi / İşlem Hataları", 4: "Erişim ve Teknik Sorunlar"

Yorumlara ağır basan konuların etiketi atandığında toplam yorum sayısına göre aldıkları ortalama beğeni grafiği ,balonların büyüklüğü toplam beğeniye ifade etmektedir.

